

《BUSHFIRE DATA QUEST 2020》技术备忘录（中文翻译）

题目：利用机器学习预测丛林火灾过火面积
Fuel Assessment Team II

摘要

本文提出了一种高效的机器学习方法，用于在检测到最初起火点后尽早预测丛林火灾的燃烧概率与过火面积。该任务对于在火灾发展为大规模灾害之前开展早期干预至关重要。为应对这种长期预测的挑战，本文将该任务定义为图像分割问题，并采用两种编码器—解码器卷积神经网络变体，即 UNet 和 BASNet。考虑到缺乏可靠的火灾起火点真实标注，本文提出从已烧毁区域中随机采样点的方法。结果表明，通过有效融合 Sentinel-2 影像、气象变量、历史火灾数据等多源信息，可以在未见过的验证集和卫星图像上获得 88% 的较高过火面积预测精度。该方法是较早成功将图像分割神经网络用于基于起火点的过火面积预测的尝试之一，可作为一种轻量级工具提供实时预测，从而辅助火灾季节的资源调配。

数据描述

研究区域位于新南威尔士州（NSW）东部，面积约 30,000 km²。卫星影像为 Sentinel-2 多光谱影像，下载自 Sentinel Australasia Regional Access (SARA) Data Hub。Sentinel-2 影像空间分辨率为 10–20 m，重访周期最短约 5 天。研究下载了 2018 年 12 月至 2020 年 7 月期间三个 100 km × 100 km 图幅（T56HKJ、T56HKH 和 T56HKG）的 Sentinel-2 Level-2A 产品（即大气底反射率）。10 个光谱波段经过云和云影掩膜处理，并重采样至 20 m 空间分辨率。

基于 Shuttle Radar Topography Mission (SRTM) 的 30 m 分辨率数字高程模型 (DEM) 从 NSW Department of Planning, Industry and Environment Data Portal 下载，并进一步重采样到 20 m，以匹配 Sentinel-2 影像。

火灾历史图层同样从 NSW Department of Planning, Industry and Environment Data Portal 以矢量格式获取。该数据集包含 1902 至 2020 年间 NSW 全境所有记录在案的野火和计划性燃烧的范围与时间信息。研究将 1902—2018 年火灾历史栅格化，构建火灾频率图层，并重采样到 20 m，以匹配 Sentinel-2 影像。气候数据来自澳大利亚气候数据库 SILO，时间范围为 2018 年 12 月至 2020 年 7 月。分析纳入了 7 个可能显著影响丛林火灾点燃概率的气象变量。这些 5 km 空间分辨率的逐日数据包括：(1) 太阳辐射（含直射和散射部分，MJ/m²）Sol_Rad；(2) 最高气温（°C）Max_temp；(3) Moreton 区域实际蒸散量（mm）ET；(4) 水汽压（hPa）Vap_Press；(5) 最高气温时刻的相对湿度（%）Rel_Humid；以及逐日总量的 (6) A 类蒸发皿蒸发量（mm）Evaporation 和 (7) 降雨量（mm）Total_rain。

方法

我们的方法是利用由 Sentinel-2 影像、栅格化天气/气候数据、DEM 栅格数据以及历史过火边界构成的数据堆栈，训练图像分割模型。过火面积数据被转为“真值”二值掩膜，作为模型训练的目标变量。本研究选用的两个模型为 UNet——一个经典的语义分割卷积神经网络，以及 BASNet——一种更新的 UNet 架构改进版本，更关注边界预测精度。

工作流程概述

图 2 展示了用于训练模型的输入流程。需要注意的是，两种模型的输入与输出预测形式并不完全相同。用于训练 BASNet 分割模型的输入包括：Sentinel-2 影像、DEM、1902—2018 年的火灾历史、天气数据、无云火前拼接影像、火前累计拼接影像，以及作为响应变量的 2018—2020 年火灾历史生成的烧毁/未烧毁二值掩膜；BASNet 还使用 1902—2018 年构建的火灾频率图层和起火点信息。模型输出为“燃烧概率”图以及过火区域预测。

响应变量

将 2018 年 12 月 16 日至 2020 年 7 月 3 日期间，位于三个 Sentinel-2 图幅（T56HKJ、T56HKK、T56HKG）内的单个火烧迹地以 20 m 分辨率栅格化，生成未烧毁（0）和已烧毁（1）的二值掩膜，作为响应变量。在研究区内，这一时期共包含 130 个由野火和计划性燃烧形成的火烧迹地。

预测变量

火灾频率图层和基于 SRTM 的 DEM 直接作为燃烧概率预测变量。为了生成无云卫星影像合成图，研究使用每次火灾事件发生前 28 天内的全部 Sentinel-2 影像构建累计拼接图像。进入每个拼接图像的像元值取自该 28 天期间归一化植被指数（NDVI）最大的时刻。也就是说，Sentinel-2 拼接影像通过为每个波段选择与最大 NDVI 对应的像元值得到。

同样，为考虑时间信息，日均气候数据在火灾发生前 28 天内进一步进行累计平均，而逐日总量则在同一时期进行累计求和。

燃烧概率预测

为了对 Sentinel-2 影像中每个 $20\text{ m} \times 20\text{ m}$ 像元预测其燃烧概率（即风险），本文基于 UNet 分割架构进行建模。我们修改了输入层，使模型接收 14 个通道的数据：10 个 Sentinel-2 波段通道、火灾开始前一段时期内的相对湿度、蒸散量、最高气温以及数字高程。模型采用交叉熵损失训练，以预测与每个输入数据堆栈对应的火烧迹地，并使用 Adam 优化器进行训练。

过火面积预测

前述模型能够学习根据燃料状况、地形和火前天气变量等特征，为每个像元赋予合理的燃烧概率；但经验上发现，其准确预测过火边界的能力有限。其主要原因在于优化所用损失函数对所有错误预测一视同仁，而不考虑其位置及与真实过火区边界的接近程度。为了解决这一问题，我们采用了 UNet 的改进版本 BASNet。新模型在整体结构上与 UNet 较为相似，但引入了结构相似性（SSIM）和交并比（IoU）目标函数，有助于将过火区域预测约束为一个更完整统一的区域。我们使用与前述相同的输入数据堆栈预测过火面积。

起火点采样

影响火灾最终过火面积的因素还有许多，例如人为干预、火灾发生期间的天气变化，以及最关键的起火点位置。若缺少这些混杂因素信息，对最终过火区域的预测本质上具有不确定性。为缓解这些数据缺失，本文提出从已烧毁区域内采样起火点。直观上，我们假设火烧迹地中的每个点都有相同概率成为起火点。训练过程中，从过火区域中均匀采样 5 个起火点，并将这些点作为额外通道输入模型。这样，模型的过火区域预测就建立在这些起火点配置条件之上。实际应用中，可用实时检测到的真实起火点替代模型生成的伪起火点，以获得更准确的预测。

多步过火面积预测

以起火点为条件不仅能提高过火面积预测精度，还赋予模型额外能力。真实火灾中，随着火线发展，新的起火点可能不断被发现。因此，理想的预测模型应能够随着时间推移、在获得新上下文信息后更新预测结果。在本研究中，这种上下文即为观测到的起火点配置。通过将新检测到的起火点不断加入既有起火点集合并重新运行模型，我们可以生成新的过火面积预测。

为展示这一能力，本文通过采样方法模拟该场景。我们假设每个已观测起火点周围服从单位标准差的高斯分布。随着更多起火点被观测到，我们向高斯混合分布中加入新的分量；并持续从当前分布中采样新的起火点，再将其加入既有集合。这样可模拟一种现实场景：距离已有起火点更近的位置具有更高燃烧概率。借助此方法，可以生成多步火灾发展图。

在实际应用中，还可以为起火点采样方法加入更多先验，例如与消防力量、城市区域、水源等的距离。此外，也可在通过其他遥感方式或地面观测方法检测到真实起火点后，直接将其输入模型。

结果与讨论

图 5 展示了 UNet 模型在一个此前未见过的地理区域上的结果。可以看到，模型能够为后来大部分被烧毁的区域（主要位于中部）赋予较高的燃烧概率。

图 6 展示了最终模型，即结合起火点采样方法的 BASNet 的结果。该模型能够较准确地预测过火区域。我们在未见验证集上实现了 88% 的总体像元级精度。

附录：技术要求

所有模型均使用 PyTorch 深度学习框架实现。训练时，两种模型都基于 20 m 分辨率下的 256×256 像素图像块进行。训练设置为 batch size 20、学习率 1e-4、权重衰减正则项 1e-4。输入图幅通过步长为 64 像素的滑动裁剪方式切分为多个图像块。推理阶段使用更大的 512×512 图像块。最后，采用滑动窗口平均与边界样条加权相结合的方法，对小块预测结果进行拼接。

在 1 块 V100 GPU 上，模型在约 100 个 Sentinel-2 图幅构成的完整训练集上训练约需 10–12 小时。源代码保存在 GitLab。